

# 에너지 수요-공급 분석을 위한 디지털트윈(EMS) 기반 서비스 모델

김행복(\*), 반승훈, 우근혁, 이민욱, 임수민, 조 민, 권기현

(\*) 강원대학교 정보통신공학과, kimhb0117@kangwon.ac.kr

## Digital twin (EMS)-based service model for energy demand-supply analysis

Kim Haeng-Bok, Ban Seung-Hun, Woo Geun-Hyeok, Lee Min-Uk, Lim Soo-Min, Cho Min, Kwon Ki-Hyeon

Kangwon National University, Department of Electronic Information Communication Engineering

### 요약

수소 기반 전력 관리 시스템인 H<sub>2</sub>EMS를 통해 그리드 전력 비용을 최소화하는 방법을 제안한다. H<sub>2</sub>EMS를 통해 그리드 전력의 변동 단가를 고려하여 에너지원 간 밸런스를 조절하기 위하여 강화학습 머신러닝 기법을 사용하였다. 잉여 전력은 수소로 변환하여 저장되고, 그리드 전력의 단가를 고려하여 공급되도록 설계하였다. 실험 결과 강화학습 기반의 H<sub>2</sub>EMS 시스템이 그리드 전력 사용량을 절감할 수 있음을 보여준다. 또한 디지털 트윈 기술을 활용하여 실제 환경을 가상 환경에 복제하고 실시간으로 모니터링 및 분석할 수 있는 기술을 개발하였다. 이를 통해 다양한 시뮬레이션을 수행하여 최적의 의사결정을 내리는데 사용한다.

## 1. 서론

효율적인 에너지 관리 제어는 태양광과 수소와 같은 분산 에너지 자원을 사용하는 소규모 전력망에서 필수적이다. 이러한 자원은 재생 가능하고 친환경적이지만, 변동성과 예측 불가능성으로 인해 관리가 어렵다. 따라서 전력망과 분산 에너지 자원을 계획적으로 사용하여 그리드 전력 사용량을 줄이고 전력 비용을 낮추는 것이 중요하다. 본 연구는 이를 위해 강화학습 기반의 신재생 에너지 최적 관리 시스템(EMS)을 제안한다. 이 시스템은 Q-Learning 알고리즘을 사용하여 최적의 운용 계획을 도출한다 [1]. 이를 통해 신재생 에너지의 변동성에 효과적으로 대응하고, 마이크로 그리드를 제어하여 자체 에너지 활용을 극대화함으로써 계통 안정성을 확보하고 전력 비용을 절감할 수 있다.

강화학습은 환경과 상호작용하며 최적의 행동을 학습하는 기법으로, 에너지 관리 시스템이 그리드 전력의 변동 단가를 실시간으로 학습하고, 에너지원 간의 밸런스를 최적화할 수 있도록 한다. 이 시스템은 잉여 전력을 수소로 변환하여 저장하고, 필요 시 그리드 전력의 단가를 고려하여 다시 전력으로 변환하는 방식으로 설계되었다. 이러한 접근은 전력 사용의 최적화와 비용 절감을 가능하게 하며, 궁극

적으로 에너지 시장의 안정성과 지속 가능성을 향상시킬 수 있다.

본 연구에서는 이러한 강화학습 기반 EMS 시스템을 디지털 트윈을 활용하여 구현하였다. 디지털 트윈은 현실 세계의 시스템을 디지털로 모델링하여 실제 상황을 시뮬레이션하고 최적의 의사 결정을 내리는 데 사용된다 [2]. 이를 통해 실제 환경에서의 시스템 동작을 시뮬레이션하고 효과적인 전력 관리 방안을 탐색할 수 있다.

본 논문은 먼저 시스템 구성 및 데이터를 점검하고, 강화학습이 아닌 다른 EMS 방식 [3]인 휴리스틱 알고리즘을 알아보고 두 방식의 차이를 확인한다. 이후 강화학습의 진행 과정을 설명하고, 최종 결과를 휴리스틱 알고리즘과 비교한다. 결론에서는 강화학습과 전통적인 휴리스틱 방식의 결과를 비교하여 그 성과를 평가한다.

## 2. EMS 디지털 트윈 설계

### 2.1 데이터

데이터는 K 대학교 S 캠퍼스 A 건물의 100kW 태양광 발전 데이터, B, C, D 건물의 212.69kW 태양광 발전 데이

터를 사용하였으며, 각 건물은 ‘교육용(을) 고압 A 섹터 1’ 전기요금을 적용받는다 [4]. 부하 데이터는 A, B, C, D 건물 소비전력을 토대로 구성했다. 각 데이터는 5분 간격이며, 단위는 kWh이다.

Table 1. Classification by season and time zone

표 1. 계절별 시간대별 구분

구분	여름철, 봄철, 가을철	겨울철
	(6~8월), (3~5월), (9~10월)	(11월~2월)
경부하	22:00~08:00	22:00~08:00
중간부하	08:00~11:00 12:00~13:00 18:00~22:00	08:00~09:00
		0
		12:00~16:00
		0
최대부하	11:00~12:00 13:00~18:00	19:00~22:00
		0
		09:00~12:00
		0
		16:00~19:00
		0

Table 2. Electricity rate

표 2. 전기요금, 교육용(을), KRW/kWh

구분	여름철	봄, 가을철	겨울철
경부하	76.5	76.5	80.5
중간부하	121.2	90.9	119.7
최대부하	187.1	111.4	158.4

## 2.2 데이터 전처리

본 연구에서 데이터의 전처리는 결측치 보정 과정을 진행했다. 태양광 데이터는 시계열 특성을 고려하여 태양광 발전 가능 시간대의 결측치를 선형 보간법[5]으로 전처리했고 나머지 시간대의 결측 발전량 데이터는 0으로 채워넣었다. A, B, C, D 건물의 부하 데이터는 학교 건물의 특성상 요일별 전력 사용 패턴 관점으로 접근했다. 요일별로 부하량 데이터를 재분류하고 각 그룹에 선형 보간법을 적용하

여 결측치를 보정했다. 각 건물의 전력 패턴을 선형 회귀 모델 학습하고 일별 부하 데이터에 대하여 모델 적용하여 데이터를 구축하였다.




Figure 1. solar data preprocessing results  
Before(top) After(bottom)

그림 1. 태양광 데이터 전처리 결과 비교  
전처리 전(상) 전처리 후(하)




Figure 2. load data preprocessing results

그림 2. 부하 데이터 전처리 결과

## 2.3 강화학습

본 연구에서는 강화학습 방법 [6] 중에서 Q-learning [7]을 사용한 비용 최소화 EMS를 제안한다. 실험에서 사용된 Q-learning 모델은 상태(State), 행동(Action), 보상(Reward)으로 구성된다. 상태는 수소 탱크의 충전 상태를 나타내며, 저장 용량은 최대 500kg으로 설정하였고, 초기 충전량은 30%로 시작한다. 상태의 가용 범위는 20%에서 90% 사이로 제한했다. 행동은 표 1에 나열된 옵션을 포함하며, 보상은 단계별 그리드 단가와 그리드 사용량을 기반으로 계산되었다(식 1).

Table 3. Action  
표 3. 액션

Action Number	PV	Hydrogen	Grid
1	O	X	X
2	O	O	X
3	O	X	O
4	O	O	O
5	X	O	X
6	X	X	O
7	X	O	O
8	X	X	X

학습 과정에서 에이전트는  $\varepsilon$ -greedy 정책을 통해 확률  $\varepsilon$ 로 무작위 행동을 선택하거나 Q-테이블에 따라 행동을 결정한다(식 2). 이 접근 방식은 그리드 비용 최적화를 위한 전략 결정에 효과적인 학습 경로를 제공한다 [8].

$$\begin{aligned} tP_{grid} &: \text{Use grid power by step} \\ tCost &: \text{Grid prices by step} \\ \text{Reward} &= tP_{grid} \cdot tCost \end{aligned} \quad (1)$$

$$\begin{aligned} \alpha &: \text{Learning rate} \\ \gamma &: \text{Discount rate} \\ \max(Q_{next}) &: \text{The maximum Q-Value among all possible actions from the next state} \\ Q_{new} &= (1-\alpha) \cdot Q_{old} + \alpha (R + \gamma \cdot \max(Q_{next})) \end{aligned} \quad (2)$$

파라미터별 이동 평균 그래프의 기울기에 절댓값을 취한 값을 구한 뒤 최종 비용으로 나눈 값에 AUC를 더해 계산된 값(식 3)을 히트맵으로 나타냈다. 그림 3은 그리드 탐색 히트맵을 나타냈다.

$$\begin{aligned} \text{Slope} &: \text{Norm}(\text{moving average value slope}) \\ \text{Price} &: \text{Norm}(\text{moving avg final grid price}) \\ \text{AUC} &: \text{Norm}(\text{Area under curve}) \\ \text{Value} &= \frac{|\text{Slope}|}{\text{price}} + \text{AUC} \end{aligned} \quad (3)$$




Figure 3. Grid Search HeatMap  
그림 3. 그리드 탐색 히트맵

그리드 탐색 히트맵을 통해 성능이 3.28로 높은 Discount rate 0.09, Learning rate 0.6 파라미터를 사용하여 300,000 에피소드의 강화학습을 진행했다.

시뮬레이션은 K 대학교 A, B, C, D 건물을 대상으로 실험을 진행했다. 수전해 장치와 연료전지는 가상으로 설정했으며, 각 0.7, 0.5의 효율과 500kg의 수소 탱크로 설정했다. 그림 4는 휴리스틱과 강화학습을 이용한 그리드 전력, 태양광, Hydrogen(수소) 저장, 수용가의 전력 사용량을 나타낸 것이다.

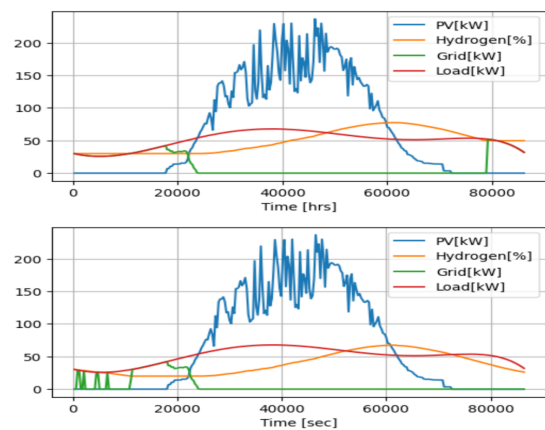


Figure 4. Results: Heuristic(top) RL(bottom)  
그림 4. 결과:휴리스틱(상) 강화학습(하)

각 비용은 아래 표와 같으며 강화학습 방법이 같은 전력 사용 환경에서 적은 비용을 사용하는 것으로 확인했다.

Table 4. Comparison of results

표 4. 결과 비교

How to optimize	Cost(단위: KRW)
heuristic algorithm	21707.59
Q-Learning	9767.43

본 연구를 통해 에너지 사용 최적화로 전기요금 절감 효과를 기대할 수 있고, 실시간 에너지 관리를 통해 에너지 사용량에 대한 모니터링과 전력 공급의 안정성 및 신뢰성 제 공할 수 있을 것으로 기대된다.

## 2.4 디지털 트윈

본 연구에서는 마인크래프트 버전 1.20을 활용하여 디지털트윈을 구현하였다. 마인크래프트는 실제 세계와 유사한 환경을 모사할 수 있어 디지털트윈 구현에 적합하다. 디지털트윈은 실제 세계의 물리적 자산, 프로세스, 시스템 등을 가상 환경에 복제하여 실시간으로 모니터링하고 분석할 수 있는 기술이다 [9], [10]. 마인크래프트 기반 디지털트윈을 통해 실제 세계의 데이터를 가상 환경에서 구현할 수 있으며, 다양한 시뮬레이션을 수행하여 실제 세계의 상황을 미리 분석할 수 있다 [11].



Figure 5. Virtual(top) Real(bottom)

그림 5. 가상(상) 실제(하)

본 연구에서는 실제 세계의 크기를 1m당 마인크래프트 블록 1개로 대체하여 구현하였다. 또한 실세계에서 수집한 데이터를 마인크래프트 내의 Item-Frame(아이템 액자)에 그래프로 나타내어 보여줌으로써, 실제 세계와 가상 세계 간의 연관성을 직관적으로 확인할 수 있도록 하였다.

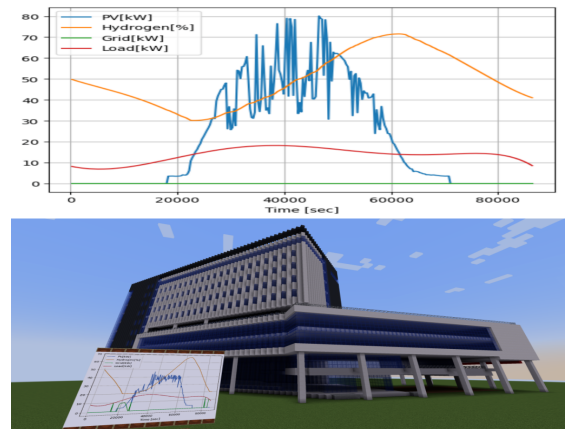


Figure 6. Real(top) Virtual(bottom)

그림 6. 실제(상) 가상(하)

## 3. 실험 및 검토

본 연구에서 수행된 모든 컴퓨터 기반 실험은 Apple MacBook Air M1(2020 모델)에서 수행되었다. 이 시스템은 macOS Sonoma 버전 14.4.1을 운영 체제로 사용하고

있으며, M1 프로세서와 16GB RAM을 탑재하고 있다. 데이터 저장에는 256GB SSD가 사용되었다. 소프트웨어 개발 및 시뮬레이션은 Python 3.8.18, Minecraft 1.20 환경에서 진행되었다.

본 연구에서는 강화학습 기반의 신재생 에너지 최적 관리 시스템과 전통적인 휴리스틱 알고리즘의 성능을 디지털 트윈 환경에서 비교하였다. 동일한 조건 하에서 두 알고리즘의 전력 누적 비용을 측정한 결과는 다음과 같다. 강화학습 기반 시스템의 전력 누적 비용은 9767.43원으로, 에너지 자원의 변동성과 예측 불가능성에 효과적으로 대응하며 마이크로그리드의 에너지 활용을 극대화하여 비용 절감 효과를 보였다. 반면, 휴리스틱 알고리즘을 사용한 시스템의 전력 누적 비용은 21707.59원으로 나타났으며, 이는 강화학습에 비해 상대적으로 높은 비용을 보였다. 두 알고리즘의 전력 누적 비용을 비교한 결과, 강화학습 기반 시스템이 휴리스틱 알고리즘에 비해 약 55% 절감 효과를 보였다. 이는 강화학습이 보다 적응적이고 효율적인 에너지 관리가 가능함을 확인시켜 준다.

## 4. 결론

본 연구에서는 강화학습 기반의 신재생 에너지 최적 관리 시스템이 전통적인 휴리스틱 알고리즘보다 전력 누적 비용을 현저히 절감할 수 있음을 실험적으로 입증하였다. 강화학습 기반 시스템은 재생 가능 에너지의 변동성과 예측 불가능성에 효과적으로 대응하며, 그리드 전력의 변동 단가를 실시간으로 학습하여 최적의 에너지 사용 계획을 도출하는 데 강점을 보였다.

디지털 트윈을 활용하여 실제 환경에서 시스템 동작을 시뮬레이션하고 최적의 의사결정을 내릴 수 있었으며, 이를 통해 에너지 관리 방안을 탐색하고 강화학습의 실효성을 확인할 수 있었다. 결과적으로, 강화학습 기반 에너지 관리 시스템은 마이크로그리드의 운영 효율성을 높이고 비용을 절감하는 데 유망한 접근 방식을 확인하였다.

## 감사의 글

본 과제(결과물)는 2024년도 교육부의 재원으로 한국연구재단의 지원을 받아 수행된 지자체-대학 협력 기반 지역 혁신 사업의 결과입니다. (2022RIS-005)

## 5. 참고 문헌

- [1] E. Samadi, A. Badri and R. Ebrahimpour, "Q-Learning-Oriented Distributed Energy Management of Grid-Connected Microgrid," 2021 29th Iranian Conference on Electrical Engineering (ICEE), Tehran, Iran, Islamic Republic of, 2021, pp. 318-322, doi: 10.1109/ICEE52715.2021.9544152.
- [2] Modu, Babangida & Abdullah, Md Pauzi & Bakar, Abba Lawan & Hamza, Mukhtar. (2023). A systematic review of hybrid renewable energy systems with hydrogen storage: Sizing, optimization, and energy management strategy. International Journal of Hydrogen Energy. 48. 10.1016/j.ijhydene.2023.06.126.
- [3] Semeraro, Concetta & Olabi, Abdul Ghani & Aljahouh, Haya & Alami, Abdul Hai & Al Radi, Muaz & Dassisti, Michele & Abdelkareem, Mohammad. (2023). Digital twin application in energy storage: Trends and challenges. Journal of Energy Storage. 58. 106347. 10.1016/j.est.2022.106347.
- [4] Korea Electric Power Corporation. (n.d.). Electricity Rate Table in Korean, for Educational Use (Type A/Type B). KEPCO ON. <https://online.kepcoco.kr/PRM004D00>
- [5] Terry, W.R. & Lee, J.B. & Kumar, Ashok. (1986). Time Series Analysis in Acid Rain Modeling: Evaluation of Filling Missing Values by Linear Interpolation. Atmospheric Environment (1967). 20. 1941-1943. 10.1016/0004-6981(86)90335-5.
- [6] W. Zhang, Z. Chen, Y. Zuo, Y. Long, H. Qiao and X. Xu, "Microgrid Energy Management Based on Sample-Efficient Reinforcement Learning," 2023 13th International Conference on Power and Energy

rgy Systems (ICPES), Chengdu, China, 2023, pp. 379-384, doi: 10.1109/ICPES59999.2023.10400136.

- [7] A. Dridi, C. Boucetta, H. Moun gla and H. Afifi, "Deep Recurrent Learning versus Q-Learning for Energy Management Systems in Next Generation Network," 2021 IEEE Global Communications Conference (GLOBECOM), Madrid, Spain, 2021, pp. 1-6, doi: 10.1109/GLOBECOM46510.2021.9685620.
- [8] H. Zhou and M. Erol-Kantarci, "Decentralized Microgrid Energy Management: A Multi-agent Correlated Q-learning Approach," 2020 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm), Tempe, AZ, USA, 2020, pp. 1-7, doi: 10.1109/SmartGridComm47815.2020.9302992.
- [9] Li, Weihang & Kwiecien, Monika & Badeda, Julia & Jost, Dominik & Schulte, Dominik & Sauer, Dirk Uwe. (2020). Digital twin for battery systems: Cloud battery management system with online state-of-charge and state-of-health estimation. *The Journal of Energy Storage*. 30. 101557. 10.1016/j.est.2020.101557.
- [10] Dellaly, Mariem & Skander-Mustapha, Sondes & Slama-Belkhodja, Ilhem. (2024). A digital twin model-based approach to cost optimization of residential community microgrids. *Global Energy Interconnection*. 7. 82-93. 10.1016/j.gloi.2024.01.008.
- [11] Xie, Haiqin & Tan, Sheng & Ling, Fengqi & Wu, Jialin & He, Liang & Zhang, Xin. (2022). Digital Twin Enabled Dual-System Reinforcement Learning Method. 2218-2223. 10.1109/SmartWorld-UIC-ATC-ScalCom-DigitalTwin-PriComp-Metaverse56740.2022.00359.